

Спостережуваність Langfuse для мультиагентної дослідницької системи

Supervisor координує Planner, Researcher і Critic у циклі Plan → Research → Critique, інструментований наскрізь Langfuse: трасування, сесії/користувачі, керування промтами, 4 LLM-as-a-Judge судді.

5 / 5 вимог закрито


4 evaluator'и

≈\$1.00 загальна вартість

Результати


ВИМОГА	ПІДТВЕРДЖЕННЯ
Трасування	4 трейси, 26-45 спанів кожен, повне дерево викликів
Сесія / користувач	Спільна сесія, ідентифікатор користувача присутній
Керування промтами	6 промтів, жодного захардкодженого тексту
LLM-as-a-Judge	4 evaluator'и, 3 типи оцінки
Скріншоти	4 з 4, у screenshots/

Архітектура



КОМПОНЕНТ	РОЛЬ	ЗВ'ЯЗОК З LANGFUSE
Supervisor	Координує цикл, єдиний запис на диск	—
Planner / Researcher / Critic	Plan → research → critique, обмежені раунди	prompt_store.py завантажує промпти
tools.py / retriever.py	Веб-пошук, читання URL, гібридний пошук	спани → observability.py
observability.py	OTel-провайдер + span processor	Tracing (Sessions / Users)
evals/langfuse_dataset.py	Синхронізує golden dataset	Datasets

Сценарій використання



КРОК	ЩО ВІДБУВАЄТЬСЯ	ВИДНО В LANGFUSE
1	Питання в REPL	—
2-4	Plan → Research → Critique (обмежені ревізії)	Дерево трейсу росте
5	Схвалення / редагування / відхилення звіту	—
6	Звіт збережено, трейс завершено	вкладка Tracing : повне дерево, сесія, користувач
7	Suddi оцінюють трейс, ~1-2 хв пізніше	вкладка Scores : 4 оцінки

Дефекти, знайдені лише живою перевіркою

Жоден з них не був видимий офлайн-набору тестів.

ДЕФЕКТ	ПРИЧИНА	ВИПРАВЛЕННЯ
Langfuse-клієнт перехопив OTel-провайдер	Створювався до конфігурації observability	Змінено порядок запуску
Кожен суддя оцінював порожній рядок	Не та пара атрибутів (trace-score замість observation-score)	Запис обох пар

ДЕФЕКТ	ПРИЧИНА	ВИПРАВЛЕННЯ
2 судді хибнопозитивили на штатному рядку про збереження	Промпти суддів не знали, що це легітимна поведінка	Промпти прямо про це попереджені

Вартість

СТАДІЯ	ВАРТІСТЬ	ПРИМІТКА
0	\$0.00	Без живих викликів
1	~\$0.06–0.15	оцінка
2	\$0.0788	виміряно
3	\$0.00	Datasets API безкоштовне
4	\$0.769	3 живих батчі
5	\$0.124	1 живий прогін
Разом	≈\$0.97–1.12	вартість суддів окремо, на боці Langfuse

Обмеження

- Кожна вартість вище — одне вимірювання, не середнє.
- Моделі-судді не валідовані проти людських оцінок.
- `citation-groundedness` перевіряє власні цитати звіту, а не реальний вилучений текст.
- Чергування research/critique не має жорсткого обмеження — один прогін коштував \$0.31 взагалі без участі критика.
- Відома, не виправлена помилка кодування консолі Windows може призвести до аварійного завершення REPL на певному тексті з веб-пошуку.

MA systems hl12 — спостережуваність Langfuse для мультиагентної дослідницької системи. Українськомовне видання (`report/report.html` — англійською).